# Diseño y evaluación experimental de un modelo documental en MongoDB para elementos transponibles y perfiles de *k*-mers

Johan Andrés Villada Valencia, María Camila Prada Cortes, Santiago Jimenez Cotrini y Cristian Camilo Arenas Salazar

***Resumen*—Los elementos transponibles (TEs) ocupan una fracción importante de los genomas eucariotas y su estudio exige bibliotecas de secuencias cada vez mayores. PanTEon Database reúne 239.946 secuencias de animales, plantas y hongos, pero las publica como archivos planos —un FASTA de 946 MiB y un CSV de 363 KiB— sin una capa de consulta que integre secuencias, taxonomía y perfiles de *k*-mers. Este trabajo diseña e implementa un modelo documental en MongoDB de tres colecciones, con referencias por `ObjectId`, desnormalización controlada y validación con `$jsonSchema`. El corpus cargado contiene 2.790 especies, 239.946 secuencias y 1.439.676 perfiles de *k*-mers ($k = 1 \ldots 6$). Las consultas analíticas y dos preguntas propias, resueltas con agregaciones, muestran que CLASSI concentra el 81,2 % de las secuencias, que LTR, LINE y TIR reúnen el 93,4 % y que Plantae está dominada por LTR mientras Animalia lo está por LINE. Comparar dos estrategias de almacenamiento muestra que agrupar los seis perfiles por secuencia reduce el espacio en disco 6,3 % y simplifica los índices. El modelo permite exportar bibliotecas FASTA por especie o reino sin reprocesar el archivo de origen.**

***Palabras clave*—bioinformática, bases de datos NoSQL, elementos transponibles, *k*-mers, modelado de datos, MongoDB**

I. Introducción
II. Trabajo relacionado
III. Materiales y métodos
*III-A. Datos y problemas de calidad*
*III-B. Modelo de datos y decisiones de diseño*
*III-C. Pipeline de procesamiento*
*III-D. Diseño experimental*
IV. Resultados
*IV-A. Consultas analíticas y generación de bibliotecas*
*IV-B. Evaluación experimental del almacenamiento de k-mers*
*IV-C. Visualización y perfiles genómicos*
V. Discusión
VI. Conclusiones
Disponibilidad de datos y código
Referencias

[1] S. Orozco-Arias, I. Ferrer-Pomer, F. Rodrigues de Góes, S. Gaviria-Orrego, J. Gómiz-Fernández, J. Llatser Torres, A. R. Paschoal, R. Guyot, and T. Gabaldón, "PanTEon: a cross-kingdom framework to guide the design of transposable element classifiers," *bioRxiv*, 2026, doi: 10.64898/2026.04.01.715927. [Online]. Available: https://doi.org/10.64898/2026.04.01.715927

[2] ——, "PanTEon database: a cross-kingdom, automatically curated reference for transposable elements," Zenodo, 2026, versión 1.6.1, conjunto de datos, licencia CC BY 4.0. doi: 10.5281/zenodo.19372616. [Online]. Available: https://zenodo.org/records/19372616

[3] J. Storer, R. Hubley, J. Rosen, T. J. Wheeler, and A. F. Smit, "The Dfam community resource of transposable element families, repeat elements, and their annotations," *Nucleic Acids Research*, vol. 49, no. D1, pp. D394–D403, 2021, doi: 10.1093/nar/gkaa1042. [Online]. Available: https://doi.org/10.1093/nar/gkaa1042

Proyecto del segundo corte de Bases de Datos II, Programa de Ingeniería de Sistemas, Universidad Autónoma de Manizales, Manizales, Colombia. Docente: Simón Gaviria Orrego.

Los datos utilizados provienen de PanTEon Database v1.6.1 (Zenodo, licencia CC BY 4.0).

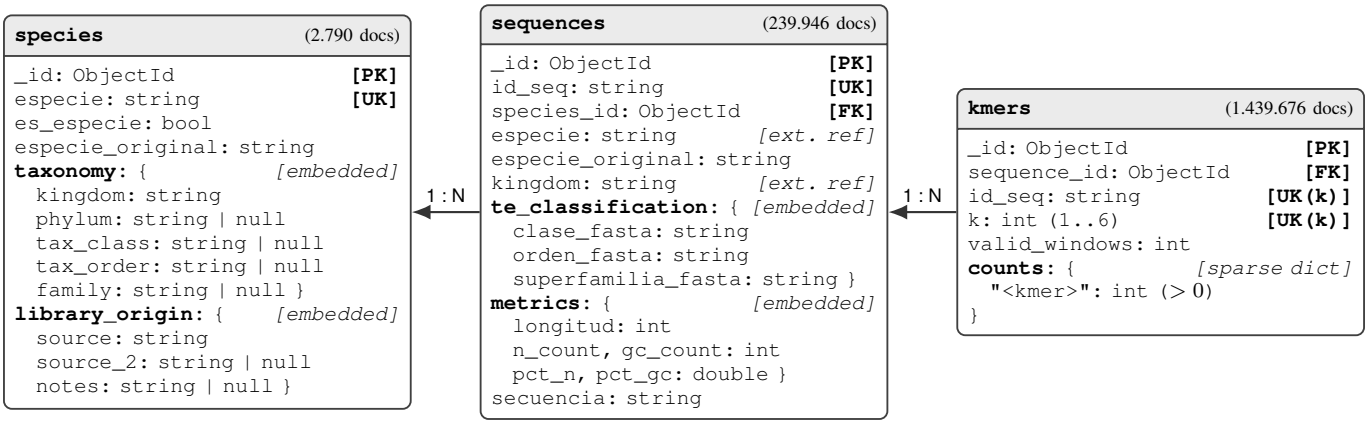



Figura 1. Diagrama del modelo documental híbrido en MongoDB. Se indican las llaves primarias (`_id`), índices únicos (`UK`), referencias por `ObjectId` (`FK`), campos desnormalizados bajo el patrón *extended reference* (`ext. ref`) y subdocumentos embebidos.