Diseño y evaluación experimental de un modelo documental en MongoDB para elementos transponibles y perfiles de *k*-mers

Johan Andrés Villada Valencia, María Camila Prada Cortes, Santiago Jimenez Cotrini y Cristian Camilo Arenas Salazar

***Resumen*—Los elementos transponibles (TEs) ocupan una fracción importante de los genomas eucariotas y su estudio exige bibliotecas de secuencias cada vez más grandes. PanTEon Database reúne 239.946 secuencias de animales, plantas y hongos, pero las publica como archivos planos —un FASTA de 946 MiB y un CSV de 363 KiB— sin una capa de consulta que integre secuencias, taxonomía y perfiles de *k*-mers. Este trabajo diseña e implementa un modelo documental en MongoDB de tres colecciones, con referencias por `ObjectId`, desnormalización controlada y validación con `$jsonSchema`. El corpus cargado contiene 2.790 especies, 239.946 secuencias y 1.439.676 perfiles de *k*-mers ($k = 1 \ldots 6$). Las consultas analíticas y dos preguntas propias, resueltas con agregaciones, muestran que CLASSI concentra el 81,2 % de las secuencias, que LTR, LINE y TIR reúnen el 93,4 % y que Plantae está dominada por LTR mientras Animalia lo está por LINE. Comparar dos estrategias de almacenamiento muestra que agrupar los seis perfiles reduce el espacio en disco 6,3 % y simplifica los índices. El modelo permite exportar bibliotecas FASTA por especie o reino sin reprocesar el archivo de origen.**

***Palabras clave*—bioinformática, bases de datos NoSQL, elementos transponibles, *k*-mers, modelado de datos, MongoDB**

I. Introducción

II. Trabajo relacionado

III. Materiales y métodos

III-A. Datos y problemas de calidad

III-B. Modelo de datos y decisiones de diseño

III-C. Pipeline de procesamiento

III-D. Diseño experimental

IV. Resultados

IV-A. Consultas analíticas y generación de bibliotecas

IV-B. Evaluación experimental del almacenamiento de k-mers

IV-C. Visualización y perfiles genómicos

V. Discusión

VI. Conclusiones

Disponibilidad de datos y código

Referencias

[1] S. Orozco-Arias, I. Ferrer-Pomer, F. Rodrigues de Góes, S. Gaviria-Orrego, J. Gómiz-Fernández, J. Llatser Torres, A. R. Paschoal, R. Guyot, and T. Gabaldón, "PanTEon: a cross-kingdom framework to guide the design of transposable element classifiers," *bioRxiv*, 2026, doi: 10.64898/2026.04.01.715927. [Online]. Available: https://doi.org/10.64898/2026.04.01.715927

[2] ——, "PanTEon database: a cross-kingdom, automatically curated reference for transposable elements," Zenodo, 2026, versión 1.6.1, conjunto de datos, licencia CC BY 4.0. doi: 10.5281/zenodo.19372616. [Online]. Available: https://zenodo.org/records/19372616

[3] J. Storer, R. Hubley, J. Rosen, T. J. Wheeler, and A. F. Smit, "The Dfam community resource of transposable element families, repeat elements, and their annotations," *Nucleic Acids Research*, vol. 49, no. D1, pp. D394–D403, 2021, doi: 10.1093/nar/gkaa1042. [Online]. Available: https://doi.org/10.1093/nar/gkaa1042

Proyecto del segundo corte de Bases de Datos II, Programa de Ingeniería de Sistemas, Universidad Autónoma de Manizales, Manizales, Colombia. Docente: Simón Gaviria Orrego.

Los datos utilizados provienen de PanTEon Database v1.6.1 (Zenodo, licencia CC BY 4.0).

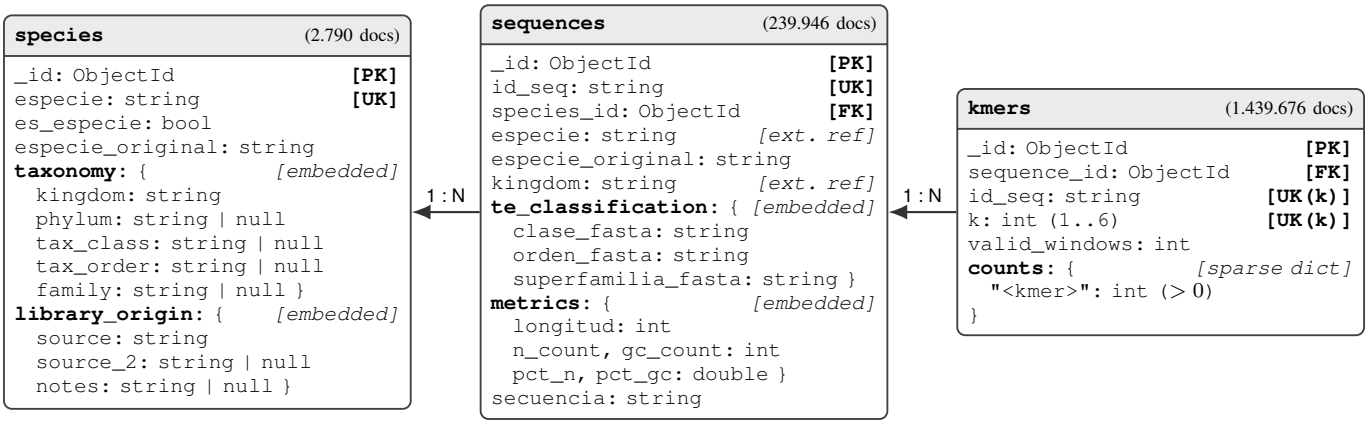


Figura 1. Diagrama del modelo documental híbrido en MongoDB. Se indican las llaves primarias (`_id`), índices únicos (`UK`), referencias por `ObjectId` (`FK`), campos desnormalizados bajo el patrón *extended reference* (`ext. ref`) y subdocumentos embebidos.